

TRƯỜNG ĐẠI HỌC KỸ THUẬT CÔNG NGHIỆP
KHOA ĐIỆN TỬ
BỘ MÔN: CÔNG NGHỆ THÔNG TIN



BÀI TIỂU LUẬN

MÔN HỌC

KHOA HỌC DỮ LIỆU

Họ và tên : Phạm Duy Tiến Minh - K225480106048

Lớp : K58.KTP

Giáo viên hướng dẫn : Ts. NGUYỄN VĂN HUY

THÁI NGUYÊN – 2026

TRƯỜNG ĐHKTCN

CỘNG HOÀ XÃ HỘI CHỦ NGHĨA VIỆT NAM

KHOA ĐIỆN TỬ

Độc lập - Tự do - Hạnh phúc

PHIẾU GIAO NHIỆM VỤ

Họ tên: Phạm Duy Tiến Minh

MSSV: K225480106048

Lớp: K58KTP

Khoá: 2022-2027

Bộ môn: Công Nghệ Thông Tin

Giáo viên hướng dẫn: Ts. NGUYỄN VĂN HUY

1. Tên đồ án: Phân tích và dự đoán khả năng đỗ đại học của học sinh

2. Các số liệu ban đầu:

Dữ liệu thực tế phù hợp với đề tài.

3. Nội dung thực hiện:

- Thu thập dữ liệu.
- Tiền xử lý dữ liệu.
- Phân tích dữ liệu.
- Trực quan hóa dữ liệu.
- Phân cụm học sinh bằng K-Means.
- Đánh giá kết quả.

4. Sản phẩm: Slide và file báo cáo

5. Ngày giao nhiệm vụ: 07/06/2026

6. Ngày hoàn thành nhiệm vụ: 20/06/2026

GIÁO VIÊN HƯỚNG DẪN

(Ký và ghi rõ họ tên)

NHẬN XÉT CỦA GIẢNG VIÊN CHẤM

Mục tiêu môn học

1. Sinh viên hiểu được quy trình thu thập, xử lý và phân tích dữ liệu trong lĩnh vực Khoa học dữ liệu.
2. Sinh viên nắm được các kỹ thuật tiền xử lý dữ liệu, trực quan hóa dữ liệu và khai thác thông tin từ dữ liệu thực tế.
3. Sinh viên biết cách sử dụng ngôn ngữ lập trình Python cùng các thư viện Pandas, NumPy, Matplotlib và Scikit-learn để giải quyết bài toán phân tích dữ liệu.
4. Sinh viên hiểu nguyên lý hoạt động của thuật toán K-Means và biết áp dụng thuật toán vào bài toán phân cụm dữ liệu thực tế.
5. Sinh viên có khả năng đánh giá, nhận xét và rút ra các kết luận từ kết quả phân tích dữ liệu.

Danh mục tính điểm

Tên kiến thức	Thang điểm	GV chấm
Thu thập dữ liệu: Xây dựng được bộ dữ liệu và đọc dữ liệu từ file Excel thành công	1	
Tiền xử lý dữ liệu: Làm sạch dữ liệu, xử lý giá trị thiếu và tính GPA chính xác	1	
Phân tích dữ liệu: Thực hiện thống kê, tính toán các chỉ số và trả lời các câu hỏi phân tích	1	
Trực quan hóa dữ liệu: Xây dựng các biểu đồ minh họa kết quả phân tích	1	
Thuật toán K-Means: Hiểu nguyên lý hoạt động và thực hiện phân cụm thành công	1	
Điểm Video	1	
Điểm Báo cáo Word	1	
Điểm Vấn đáp các câu hỏi khác	3	
Tổng điểm		

GIÁO VIÊN HƯỚNG DẪN
(Ký ghi rõ họ tên)

MỤC LỤC

MỤC LỤC.....	1
LỜI CAM ĐOAN	3
DANH MỤC CÁC BẢNG VÀ HÌNH VẼ, ĐỒ THỊ.....	4
LỜI NÓI ĐẦU.....	5
CHƯƠNG 1: GIỚI THIỆU.....	6
1.1. Lý do chọn đề tài.....	6
1.2. Mục tiêu nghiên cứu.....	6
1.3. Đối tượng nghiên cứu.....	7
1.4. Phạm vi nghiên cứu.....	7
1.5. Phương pháp nghiên cứu.....	7
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT	9
2.1. Khoa học dữ liệu.....	9
2.2. Phân tích dữ liệu	9
2.3. Trực quan hóa dữ liệu	10
2.4. Thuật toán K-Means	10
2.5. Thuật toán Random Forest.....	11
2.6. Thuật toán Logistic Regression.....	11
2.7. Thư viện sử dụng	12
CHƯƠNG 3. THU THẬP VÀ TIỀN XỬ LÝ DỮ LIỆU	13
3.1. Giới thiệu bộ dữ liệu	13
3.2. Thu thập dữ liệu.....	13
3.3. Tiền xử lý dữ liệu.....	13
3.4. Công cụ sử dụng	15

3.5. Quy trình thực hiện	17
CHƯƠNG 4. PHÂN TÍCH DỮ LIỆU.....	19
4.1. Điểm trung bình của học sinh	19
4.2. Cách tính điểm trung bình môn học	20
4.3. Thống kê xếp loại học lực.....	20
4.4. Học sinh có điểm trung bình cao nhất.....	21
4.5. Phân cụm học sinh bằng thuật toán K-Means	22
4.6. Dự đoán khả năng đỗ đại học bằng Random Forest và Logistic Regression	23
4.7. Nhận xét chung.....	24
CHƯƠNG 5. PHÂN CỤM VÀ DỰ ĐOÁN KHẢ NĂNG ĐỖ ĐẠI HỌC	25
5.1. Giới thiệu bài toán phân cụm và dự đoán	25
5.2. Chuẩn bị dữ liệu.....	25
5.3. Thực hiện phân cụm bằng thuật toán K-Means.....	26
5.4. Kết quả phân cụm	27
5.5. Dự đoán khả năng đỗ đại học.....	28
5.6. Đánh giá kết quả	30
TÀI LIỆU THAM KHẢO.....	31

LỜI CAM ĐOAN

Em xin cam đoan đề tài “*Phân tích và dự đoán khả năng đỗ đại học của học sinh*” là công trình nghiên cứu do chính em thực hiện. Các dữ liệu sử dụng trong báo cáo được tái tạo ngẫu nhiên để làm mẫu thử nghiệm.

Các kết quả phân tích, nhận xét và đánh giá được trình bày trong báo cáo là kết quả nghiên cứu của riêng em. Những tài liệu tham khảo được sử dụng trong báo cáo đều được trích dẫn đầy đủ theo đúng quy định.

Em xin hoàn toàn chịu trách nhiệm về tính chính xác và trung thực của nội dung bài này.

Tên học sinh
Minh
Phạm Duy Tiến Minh

DANH MỤC CÁC BẢNG VÀ HÌNH VẼ, ĐỒ THỊ

Hình 4.1: Biểu đồ phân bố điểm trung bình học sinh

Hình 4.2: Biểu đồ thống kê xếp loại học lực học sinh

Hình 4.3: Biểu đồ Top học sinh có điểm trung bình cao nhất

Hình 4.4: Phân cụm học sinh bằng K-Means

Hình 4.5: Random Forest và Logistic Regression

Hình 5.1: Biểu đồ kết quả phân cụm K-Means

Hình 5.2: Danh sách thống kê dự đoán Đổ Trượt

Hình 5.3: Thống kê chi tiết và đánh giá có thể cải thiện để Đổ

LỜI NÓI ĐẦU

Ngày nay, cùng với sự phát triển mạnh mẽ của cuộc Cách mạng Công nghiệp 4.0, khoa học dữ liệu và trí tuệ nhân tạo đang ngày càng khẳng định vai trò quan trọng trong nhiều lĩnh vực của đời sống. Việc khai thác và phân tích dữ liệu không chỉ giúp các tổ chức, doanh nghiệp đưa ra những quyết định chính xác hơn mà còn góp phần nâng cao hiệu quả quản lý, tối ưu hóa nguồn lực và dự báo các xu hướng trong tương lai. Đặc biệt, trong lĩnh vực giáo dục, khoa học dữ liệu đã trở thành một công cụ hữu ích nhằm hỗ trợ đánh giá, phân tích và dự đoán kết quả học tập của học sinh, học sinh.

Trong bối cảnh cạnh tranh ngày càng cao của các kỳ thi tuyển sinh đại học, việc phân tích các yếu tố ảnh hưởng đến kết quả học tập và khả năng trúng tuyển của học sinh có ý nghĩa rất quan trọng. Thông qua việc áp dụng các phương pháp phân tích dữ liệu và các mô hình học máy, có thể nhận diện được những yếu tố tác động đến kết quả học tập, từ đó đưa ra các dự đoán và hỗ trợ học sinh xây dựng kế hoạch học tập phù hợp. So với các phương pháp đánh giá truyền thống, việc ứng dụng khoa học dữ liệu mang lại khả năng xử lý khối lượng dữ liệu lớn, nâng cao độ chính xác và cung cấp những thông tin có giá trị cho quá trình ra quyết định.

Nhận thức được tầm quan trọng và tiềm năng ứng dụng của khoa học dữ liệu trong lĩnh vực giáo dục, em đã lựa chọn thực hiện đề tài “Phân tích và dự đoán khả năng đỗ đại học của học sinh”. Mục tiêu của đề tài là nghiên cứu, phân tích các yếu tố ảnh hưởng đến kết quả học tập của học sinh, đồng thời xây dựng mô hình dự đoán khả năng đỗ đại học dựa trên các đặc điểm đầu vào như điểm số, thời gian học tập và số lần nghỉ học. Bên cạnh đó, đề tài còn hướng đến việc phân nhóm các học sinh có đặc điểm tương đồng nhằm hỗ trợ việc đánh giá và định hướng học tập hiệu quả hơn.

Mặc dù đã có nhiều cố gắng trong quá trình nghiên cứu và thực hiện, nhưng do kiến thức chuyên môn và thời gian còn hạn chế nên bài tiểu luận chắc chắn không tránh khỏi những thiếu sót. Em rất mong nhận được những ý kiến đóng góp quý báu từ các thầy cô để đề tài được hoàn thiện hơn.

Em xin chân thành cảm ơn!

CHƯƠNG 1: GIỚI THIỆU

1.1. Lý do chọn đề tài

Trong những năm gần đây, khoa học dữ liệu và trí tuệ nhân tạo đã được ứng dụng rộng rãi trong nhiều lĩnh vực khác nhau như kinh tế, y tế, thương mại và giáo dục. Đặc biệt, trong lĩnh vực giáo dục, việc khai thác và phân tích dữ liệu học tập của học sinh giúp các nhà quản lý, giáo viên và học sinh có cái nhìn toàn diện hơn về các yếu tố ảnh hưởng đến kết quả học tập, từ đó đưa ra những định hướng phù hợp nhằm nâng cao chất lượng giáo dục.

Kỳ thi tuyển sinh đại học là một cột mốc quan trọng đối với mỗi học sinh, quyết định cơ hội tiếp cận môi trường học tập và nghề nghiệp trong tương lai. Tuy nhiên, khả năng đỗ đại học chịu ảnh hưởng bởi nhiều yếu tố khác nhau như điểm số các môn học, thời gian học tập, mức độ chuyên cần và kết quả học tập tổng thể. Việc phân tích các yếu tố này bằng các phương pháp truyền thống thường mất nhiều thời gian và khó đưa ra các dự đoán chính xác.

Xuất phát từ thực tế đó, em lựa chọn đề tài “Phân tích và dự đoán khả năng đỗ đại học của học sinh” nhằm nghiên cứu, khai thác dữ liệu học tập của học sinh, từ đó xác định các yếu tố có ảnh hưởng đến kết quả xét tuyển đại học và xây dựng mô hình dự đoán khả năng đỗ đại học. Bên cạnh đó, đề tài còn giúp em vận dụng các kiến thức đã học về khoa học dữ liệu, phân tích dữ liệu và học máy vào một bài toán thực tế trong lĩnh vực giáo dục.

Thông qua đề tài này, em mong muốn góp phần làm rõ vai trò của khoa học dữ liệu trong việc hỗ trợ quá trình học tập và định hướng giáo dục, đồng thời nâng cao khả năng nghiên cứu và ứng dụng các kỹ thuật phân tích dữ liệu vào thực tiễn.

1.2. Mục tiêu nghiên cứu

Đề tài được thực hiện nhằm đạt được các mục tiêu sau:

- Thu thập và xử lý dữ liệu điểm thi của học sinh từ bộ dữ liệu được xây dựng.
- Phân tích kết quả học tập của học sinh thông qua các chỉ số thống kê như điểm trung bình, xếp loại học lực và tỷ lệ đỗ đại học.
- Trực quan hóa dữ liệu bằng các biểu đồ nhằm hỗ trợ việc đánh giá và so sánh kết quả học tập.
- Áp dụng thuật toán K-Means để phân cụm học sinh dựa trên các đặc điểm học tập như GPA, số giờ học mỗi tuần và số buổi nghỉ học.
- Xây dựng mô hình học máy Random Forest và Logistic Regression để dự đoán khả năng đỗ hoặc trượt đại học của học sinh.

- Đưa ra nhận xét và đánh giá về mối quan hệ giữa kết quả học tập và khả năng trúng tuyển đại học.

1.3. Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là dữ liệu học sinh tham gia kỳ thi tốt nghiệp trung học phổ thông và xét tuyển đại học.

Dữ liệu bao gồm:

- Mã học sinh.
- Giới tính.
- Điểm các môn.
- Số giờ học mỗi tuần.
- Số buổi nghỉ học.
- Trình độ học vấn của phụ huynh.
- Thu nhập gia đình.
- Khôi xét tuyển đại học.
- Trường đại học đăng ký.
- Điểm xét tuyển.
- Kết quả đỗ hoặc trượt đại học.

1.4. Phạm vi nghiên cứu

Đề tài tập trung nghiên cứu dữ liệu học sinh được lưu trữ trong file Excel và thực hiện các bước xử lý, phân tích trên môi trường Python.

Các nội dung nghiên cứu bao gồm:

- Phân tích thống kê dữ liệu điểm thi của học sinh.
- Tính toán điểm trung bình (GPA) và xếp loại học lực.
- Trực quan hóa dữ liệu bằng các biểu đồ.
- Phân cụm học sinh bằng thuật toán K-Means.
- Xây dựng mô hình dự đoán khả năng đỗ đại học bằng Random Forest và Logistic Regression.

Đề tài không nghiên cứu các yếu tố tâm lý, điều kiện xã hội hoặc các yếu tố bên ngoài khác có thể ảnh hưởng đến kết quả thi của học sinh ngoài những thuộc tính đã có trong bộ dữ liệu.

1.5. Phương pháp nghiên cứu

Đề tài sử dụng các phương pháp nghiên cứu sau:

- Phương pháp thu thập dữ liệu từ bộ dữ liệu học sinh được xây dựng và lưu trữ dưới dạng file Excel.
- Phương pháp xử lý và làm sạch dữ liệu bằng ngôn ngữ Python.
- Phương pháp phân tích thống kê mô tả nhằm đánh giá kết quả học tập

của học sinh.

- Phương pháp trực quan hóa dữ liệu bằng biểu đồ để hỗ trợ phân tích.
- Phương pháp học máy không giám sát sử dụng thuật toán K-Means để phân cụm học sinh.
- Phương pháp học máy có giám sát sử dụng Random Forest và Logistic Regression để dự đoán khả năng đỗ hoặc trượt đại học.
- Phương pháp đánh giá mô hình thông qua độ chính xác (Accuracy) nhằm so sánh hiệu quả của các thuật toán dự đoán.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

2.1 Khoa học dữ liệu

Khoa học dữ liệu (Data Science) là lĩnh vực kết hợp giữa thống kê, lập trình và học máy nhằm thu thập, xử lý, phân tích và khai thác tri thức từ dữ liệu. Mục tiêu của khoa học dữ liệu là tìm ra những thông tin có giá trị từ dữ liệu để hỗ trợ quá trình ra quyết định.

Hiện nay, khoa học dữ liệu được ứng dụng rộng rãi trong nhiều lĩnh vực như kinh doanh, tài chính, y tế và giáo dục. Trong lĩnh vực giáo dục, khoa học dữ liệu giúp phân tích kết quả học tập, đánh giá chất lượng đào tạo và hỗ trợ đưa ra các giải pháp nâng cao hiệu quả học tập của học sinh.

Trong đề tài này, khoa học dữ liệu được sử dụng để phân tích dữ liệu điểm học tập của học sinh, từ đó đánh giá tình hình học tập và phân nhóm học sinh theo kết quả học tập.

2.2 Phân tích dữ liệu

Phân tích dữ liệu (Data Analysis) là quá trình thu thập, xử lý, kiểm tra và tổng hợp dữ liệu nhằm tìm ra những thông tin có giá trị phục vụ cho việc nghiên cứu và hỗ trợ ra quyết định.

Quá trình phân tích dữ liệu thường bao gồm các bước:

- Thu thập dữ liệu.
- Làm sạch và tiền xử lý dữ liệu.
- Phân tích thống kê.
- Trực quan hóa dữ liệu.
- Xây dựng mô hình dự đoán.
- Đưa ra kết luận và nhận xét.

Trong đề tài này, phân tích dữ liệu được sử dụng để:

- Tính điểm trung bình (GPA) của từng học sinh.
- Thống kê số lượng học sinh theo từng mức học lực.
- Xác định nhóm học sinh có kết quả học tập cao nhất.
- Phân tích tỷ lệ đỗ và trượt đại học.
- Đánh giá mối quan hệ giữa kết quả học tập và khả năng trúng tuyển đại học.
- Chuẩn bị dữ liệu cho quá trình phân cụm và dự đoán.

Thông qua quá trình phân tích dữ liệu, đề tài có thể rút ra các đặc điểm quan trọng của bộ dữ liệu và hỗ trợ việc xây dựng các mô hình học máy ở các bước tiếp theo.

2.3. Trực quan hóa dữ liệu

Trực quan hóa dữ liệu (Data Visualization) là quá trình biểu diễn dữ liệu dưới dạng hình ảnh như biểu đồ, đồ thị hoặc sơ đồ nhằm giúp người dùng dễ dàng quan sát và hiểu được các đặc điểm của dữ liệu.

Việc trực quan hóa dữ liệu giúp:

- Quan sát xu hướng và sự phân bố dữ liệu.
- So sánh các nhóm dữ liệu khác nhau.
- Phát hiện các điểm bất thường trong dữ liệu.
- Hỗ trợ trình bày kết quả phân tích một cách trực quan.

Trong đề tài này, các biểu đồ được sử dụng gồm:

- Biểu đồ cột thể hiện số lượng học sinh theo từng mức học lực.
- Biểu đồ phân bố điểm trung bình GPA của học sinh.
- Biểu đồ Top 10 học sinh có điểm trung bình cao nhất.
- Biểu đồ phân tán thể hiện kết quả phân cụm K-Means.
- Các biểu đồ thống kê phục vụ đánh giá kết quả phân tích dữ liệu.

Nhờ trực quan hóa dữ liệu, các kết quả nghiên cứu được trình bày rõ ràng và dễ dàng so sánh hơn.

2.4. Thuật toán K-Means

K-Means là một thuật toán học máy không giám sát (Unsupervised Learning) được sử dụng phổ biến trong bài toán phân cụm dữ liệu. Mục tiêu của thuật toán là chia tập dữ liệu thành K nhóm sao cho các đối tượng trong cùng một nhóm có đặc điểm tương đồng với nhau.

Thuật toán K-Means hoạt động theo các bước sau:

Bước 1: Chọn số cụm K.

Bước 2: Khởi tạo ngẫu nhiên K tâm cụm (Centroid).

Bước 3: Tính khoảng cách từ từng điểm dữ liệu đến các tâm cụm và gán điểm dữ liệu vào cụm gần nhất.

Bước 4: Tính lại vị trí tâm cụm dựa trên các phần tử thuộc cụm.

Bước 5: Lặp lại quá trình trên cho đến khi các tâm cụm không còn thay đổi hoặc đạt số lần lặp tối đa.

Trong đề tài này, thuật toán K-Means được sử dụng để phân nhóm học sinh

dựa trên các đặc trưng:

- Điểm trung bình GPA.
- Số giờ học mỗi tuần.
- Số buổi nghỉ học.

Kết quả phân cụm giúp nhận biết các nhóm học sinh có đặc điểm học tập tương đồng, từ đó hỗ trợ việc đánh giá và đưa ra các phương pháp học tập phù hợp.

2.5. Thuật toán Random Forest

Random Forest là một thuật toán học máy có giám sát (Supervised Learning) được sử dụng phổ biến trong các bài toán phân loại và dự đoán.

Thuật toán Random Forest hoạt động bằng cách xây dựng nhiều cây quyết định (Decision Tree) khác nhau, sau đó tổng hợp kết quả của các cây để đưa ra dự đoán cuối cùng.

Ưu điểm của Random Forest:

- Độ chính xác cao.
- Hạn chế hiện tượng quá khớp (Overfitting).
- Hoạt động tốt với dữ liệu có nhiều thuộc tính.
- Khả năng dự đoán ổn định và hiệu quả.

Trong đề tài này, Random Forest được sử dụng để dự đoán khả năng đỗ hoặc trượt đại học của học sinh dựa trên:

- Điểm các môn học.
- Số giờ học mỗi tuần.
- Số buổi nghỉ học.

Kết quả dự đoán của mô hình được đánh giá thông qua độ chính xác (Accuracy).

2.6. Thuật toán Logistic Regression

Logistic Regression là thuật toán học máy có giám sát được sử dụng phổ biến trong các bài toán phân loại nhị phân.

Mục tiêu của Logistic Regression là xác định xác suất một đối tượng thuộc vào một trong hai lớp dữ liệu khác nhau.

Trong đề tài này, Logistic Regression được sử dụng để:

- Dự đoán khả năng đỗ đại học của học sinh.
- So sánh hiệu quả với mô hình Random Forest.
- Đánh giá khả năng ứng dụng của các thuật toán học máy trong bài toán dự đoán kết quả tuyển sinh.

Việc sử dụng đồng thời hai mô hình giúp tăng tính khách quan và nâng cao độ tin cậy của kết quả nghiên cứu.

2.7. Thư viện sử dụng

Để thực hiện đề tài, một số thư viện Python được sử dụng như:

- **Pandas**: Đọc và xử lý dữ liệu từ file Excel.
- **Matplotlib**: Trực quan hóa dữ liệu bằng biểu đồ.
- **Scikit-learn**: Cung cấp các thuật toán K-Means, Random Forest và Logistic Regression.
- **OpenPyXL**: Hỗ trợ tạo và xuất báo cáo kết quả dưới dạng file Excel.
- **NumPy**: Hỗ trợ tính toán số học và xử lý dữ liệu.

Các thư viện trên giúp quá trình xử lý, phân tích, trực quan hóa và dự đoán dữ liệu được thực hiện một cách hiệu quả và chính xác.

CHƯƠNG 3. THU THẬP VÀ TIỀN XỬ LÝ DỮ LIỆU

3.1 Giới thiệu bộ dữ liệu

Bộ dữ liệu sử dụng trong đề tài là dữ liệu điểm thi của học sinh tham gia kỳ thi tốt nghiệp trung học phổ thông và xét tuyển đại học. Dữ liệu được xây dựng và lưu trữ dưới dạng file Excel nhằm phục vụ cho quá trình phân tích, phân cụm và dự đoán khả năng đỗ đại học của học sinh.

Bộ dữ liệu bao gồm các thông tin:

- Mã học sinh.
- Giới tính.
- Điểm các môn.
- Số giờ học mỗi tuần.
- Số buổi nghỉ học.
- Điểm trung bình (GPA).
- Kết quả đỗ hoặc trượt đại học.

Bộ dữ liệu gồm khoảng 500 học sinh và được sử dụng làm cơ sở cho quá trình phân tích thống kê, trực quan hóa dữ liệu, phân cụm học sinh bằng thuật toán K-Means và xây dựng mô hình dự đoán khả năng đỗ đại học.

3.2. Thu thập dữ liệu

Dữ liệu được tự tái tạo và lưu trữ trong file Excel "**du_lieu_diem.xlsx**". File dữ liệu được đọc vào môi trường Python thông qua thư viện Pandas để phục vụ cho quá trình xử lý và phân tích.

Việc sử dụng dữ liệu thực tế giúp kết quả nghiên cứu có tính khách quan và phản ánh tương đối chính xác đặc điểm học tập của học sinh.

Sau khi đọc dữ liệu, chương trình tiến hành kiểm tra số lượng học sinh, số lượng thuộc tính và cấu trúc dữ liệu nhằm đảm bảo dữ liệu đáp ứng yêu cầu của bài toán nghiên cứu.

3.3. Tiền xử lý dữ liệu

Sau khi thu thập dữ liệu từ file Excel, dữ liệu chưa thể được sử dụng ngay cho quá trình phân tích do có thể tồn tại các giá trị thiếu, dữ liệu sai định dạng hoặc chưa được chuẩn hóa. Vì vậy, cần tiến hành tiền xử lý dữ liệu nhằm đảm bảo tính chính xác và độ tin cậy của kết quả phân tích.

Đọc dữ liệu từ file Excel

Dữ liệu điểm thi của học sinh được lưu trữ trong file Excel. Để xử lý dữ liệu

bằng Python, đề tài sử dụng thư viện Pandas để đọc dữ liệu từ file Excel và chuyển đổi thành cấu trúc DataFrame.

Việc sử dụng DataFrame giúp dễ dàng thực hiện các thao tác:

- Quản lý dữ liệu dưới dạng bảng.
- Lọc dữ liệu theo từng thuộc tính.
- Thực hiện các phép tính thống kê.
- Chuẩn bị dữ liệu cho các thuật toán học máy.

Sau khi đọc dữ liệu thành công, chương trình tiến hành kiểm tra:

- Số lượng dòng dữ liệu.
- Số lượng thuộc tính.
- Kiểu dữ liệu của từng cột.
- Các giá trị thiếu hoặc dữ liệu bất thường.

Làm sạch dữ liệu

Trong quá trình xây dựng dữ liệu, một số giá trị có thể bị nhập sai hoặc chưa thống nhất về định dạng. Vì vậy, dữ liệu cần được làm sạch trước khi đưa vào phân tích.

Các công việc được thực hiện bao gồm:

- Kiểm tra dữ liệu trùng lặp.
- Loại bỏ các giá trị không hợp lệ.
- Chuyển đổi dữ liệu sang đúng kiểu dữ liệu số.
- Chuẩn hóa các giá trị điểm theo cùng một thang điểm.
- Kiểm tra các thuộc tính phục vụ cho mô hình dự đoán.

Quá trình làm sạch dữ liệu giúp nâng cao chất lượng của bộ dữ liệu và giảm thiểu sai lệch trong quá trình phân tích.

Xử lý giá trị thiếu

Trong bộ dữ liệu có thể xuất hiện các ô dữ liệu trống do chưa được cập nhật đầy đủ hoặc học sinh chưa có thông tin tương ứng.

Để đảm bảo độ chính xác của kết quả phân tích, chương trình tiến hành:

- Phát hiện các giá trị thiếu.
- Kiểm tra mức độ ảnh hưởng của dữ liệu thiếu.
- Loại bỏ hoặc xử lý các giá trị không cần thiết.

- Đảm bảo dữ liệu đầu vào phù hợp với các thuật toán học máy.

Việc xử lý dữ liệu thiếu giúp tăng tính đầy đủ và độ tin cậy của bộ dữ liệu trước khi tiến hành phân tích.

Tính điểm trung bình

Sau khi dữ liệu đã được làm sạch và chuẩn hóa, tiến hành tính điểm trung bình (GPA) của từng học sinh dựa trên điểm của tám môn học trong bộ dữ liệu.

Điểm trung bình được tính theo công thức:

$$[GPA = \frac{\sum_{i=1}^n Điểm_i}{n}]$$

Trong đó:

- (Điểm_i): Điểm của môn học thứ (i).
- (n): Tổng số môn học được sử dụng để tính GPA.

Điểm trung bình được sử dụng để:

- Đánh giá kết quả học tập của từng học sinh.
- Xếp loại học lực thành các mức Giỏi, Khá và Trung bình.
- Phân tích và trực quan hóa dữ liệu.
- Làm dữ liệu đầu vào cho thuật toán K-Means.
- Hỗ trợ xây dựng mô hình dự đoán khả năng đỗ đại học bằng Random Forest và Logistic Regression.

Kết quả tính toán GPA đóng vai trò quan trọng trong toàn bộ quá trình nghiên cứu và là cơ sở để đưa ra các nhận xét, đánh giá cũng như kết luận của đề tài.

3.4 Công cụ sử dụng:

Để thực hiện đề tài “**Phân tích và dự đoán khả năng đỗ đại học**”, ngôn ngữ lập trình **Python** được lựa chọn do có khả năng xử lý dữ liệu mạnh mẽ, cú pháp đơn giản và được sử dụng rộng rãi trong lĩnh vực Khoa học dữ liệu, Học máy (Machine Learning) và Trí tuệ nhân tạo. Bên cạnh đó, đề tài còn sử dụng nhiều thư viện phổ biến của Python nhằm hỗ trợ quá trình tiền xử lý dữ liệu, phân tích, trực quan hóa và xây dựng mô hình dự đoán.

Pandas

Pandas là thư viện chuyên dùng để xử lý và phân tích dữ liệu có cấu trúc trong Python. Thư viện này cung cấp cấu trúc dữ liệu DataFrame giúp lưu trữ và quản lý dữ liệu dưới dạng bảng tương tự như Excel.

Trong đề tài, Pandas được sử dụng để:

- Đọc dữ liệu từ file Excel.
- Quản lý dữ liệu thông tin và điểm thi của học sinh.
- Lọc dữ liệu và xử lý dữ liệu thiếu.
- Tính toán điểm trung bình GPA của học sinh.
- Sắp xếp và phân loại học lực.
- Chuẩn bị dữ liệu cho quá trình phân tích và xây dựng mô hình dự đoán.

Nhờ Pandas, việc thao tác với dữ liệu trở nên nhanh chóng, chính xác và thuận tiện hơn.

Matplotlib

Matplotlib là thư viện hỗ trợ trực quan hóa dữ liệu bằng các biểu đồ trong Python.

Trong đề tài, Matplotlib được sử dụng để:

- Vẽ biểu đồ thống kê số lượng học sinh theo từng mức học lực.
- Vẽ biểu đồ phân bố điểm trung bình GPA.
- Vẽ biểu đồ Top học sinh có điểm trung bình cao nhất.
- Minh họa kết quả phân cụm dữ liệu bằng biểu đồ phân tán.
- Hỗ trợ trực quan hóa dữ liệu nhằm dễ dàng phân tích và đánh giá kết quả.

Việc sử dụng Matplotlib giúp các kết quả phân tích trở nên trực quan và dễ hiểu hơn.

Scikit-learn (Sklearn)

Scikit-learn là thư viện Học máy phổ biến trong Python, cung cấp nhiều thuật toán phục vụ phân loại, hồi quy và phân cụm dữ liệu.

Trong đề tài, Scikit-learn được sử dụng để:

- Áp dụng thuật toán K-Means để phân cụm học sinh theo đặc điểm học tập.
- Xây dựng mô hình Random Forest nhằm dự đoán khả năng đỗ hoặc trượt đại học.
- Xây dựng mô hình Logistic Regression để so sánh hiệu quả dự đoán.
- Chia tập dữ liệu thành tập huấn luyện và tập kiểm tra.
- Đánh giá độ chính xác của các mô hình dự đoán.

Nhờ Scikit-learn, việc triển khai các thuật toán học máy trở nên đơn giản và hiệu quả hơn.

OpenPyXL

OpenPyXL là thư viện hỗ trợ đọc và ghi file Excel định dạng .xlsx trong Python.

Trong đề tài, OpenPyXL được sử dụng để:

- Tạo file báo cáo kết quả dưới dạng Excel.
- Xuất danh sách học sinh và kết quả phân tích.
- Tạo nhiều Sheet thống kê khác nhau.
- Định dạng bảng dữ liệu và chèn biểu đồ vào báo cáo.
- Hỗ trợ xây dựng báo cáo tổng hợp trực quan và chuyên nghiệp.

Microsoft Excel

Microsoft Excel được sử dụng làm công cụ lưu trữ dữ liệu đầu vào và kết quả đầu ra của chương trình.

Excel được sử dụng để:

- Lưu bộ dữ liệu học sinh.
- Quản lý thông tin điểm thi và các thuộc tính liên quan.
- Lưu báo cáo phân tích sau khi chương trình xử lý.
- Hỗ trợ kiểm tra và đối chiếu dữ liệu một cách thuận tiện.

Nhờ khả năng xử lý bảng tính linh hoạt, Excel giúp quá trình quản lý dữ liệu trở nên dễ dàng và hiệu quả hơn.

Visual Studio Code

Visual Studio Code là môi trường phát triển tích hợp (IDE) được sử dụng để xây dựng và chạy chương trình Python.

Trong đề tài, Visual Studio Code được sử dụng để:

- Viết và chỉnh sửa mã nguồn Python.
- Quản lý các thư viện cần thiết cho chương trình.
- Chạy và kiểm thử chương trình.
- Hỗ trợ phát hiện và sửa lỗi trong quá trình phát triển.

Visual Studio Code cung cấp giao diện thân thiện và nhiều tiện ích hỗ trợ lập trình, giúp nâng cao hiệu quả làm việc trong quá trình thực hiện đề tài.

3.5 Quy trình thực hiện

Quy trình thực hiện đề tài gồm các bước:

- Thu thập dữ liệu từ file Excel.

- Tiền xử lý và làm sạch dữ liệu.
- Tính toán các chỉ số thống kê.
- Phân tích dữ liệu và trực quan hóa.
- Phân cụm học sinh bằng thuật toán K-Means.
- Đánh giá và nhận xét kết quả.

Quy trình trên đảm bảo dữ liệu được xử lý một cách khoa học và phục vụ hiệu quả cho mục tiêu nghiên cứu của đề tài.

CHƯƠNG 4. PHÂN TÍCH DỮ LIỆU

4.1. Điểm trung bình của học sinh

Sau khi hoàn thành quá trình làm sạch và tiền xử lý dữ liệu, đề tài tiến hành tính điểm trung bình (GPA) cho từng học sinh. GPA được tính dựa trên điểm của tám môn học gồm: Toán, Ngữ văn, Ngoại ngữ, Vật lý, Hóa học, Sinh học, Lịch sử và Địa lý.

Công thức tính GPA được sử dụng như sau:

$$[GPA = \frac{\sum_{i=1}^n Điểm_i}{n}]$$

Trong đó:

- Điểm i: Điểm của môn học thứ i.
- n: Tổng số môn học được sử dụng để tính GPA.

Sau khi tính GPA cho từng học sinh, đề tài tiếp tục tính điểm trung bình chung của toàn bộ học sinh theo công thức:

$$[\overline{GPA} = \frac{\sum_{j=1}^m GPA_j}{m}]$$

Trong đó:

- GPA_j: Điểm trung bình của học sinh thứ j.
- m: Tổng số học sinh trong bộ dữ liệu.


Kết quả phân tích cho thấy điểm trung bình của học sinh tập trung chủ yếu trong khoảng từ 6,5 đến 8,0 điểm. Điều này phản ánh mặt bằng học tập tương đối ổn định của đa số học sinh tham gia khảo sát.

Theo thang đánh giá được sử dụng trong đề tài:

- Giỏi: GPA $\geq 8,0$
- Khá: $6,5 \leq GPA < 8,0$
- Trung bình: GPA $< 6,5$

Biểu đồ phân bố GPA cho thấy phần lớn học sinh thuộc nhóm Khá và Giỏi. Điều này chứng tỏ chất lượng học tập của học sinh nhìn chung ở mức tốt và có khả năng đáp ứng yêu cầu xét tuyển đại học.

Kết quả này là cơ sở quan trọng để thực hiện các bước phân tích tiếp theo và áp dụng thuật toán phân cụm K-Means nhằm nhóm các học sinh có đặc điểm học tập tương đồng.



Hình 4.1: Biểu đồ phân bố điểm trung bình học sinh

4.2. Cách tính điểm trung bình môn học

Để đánh giá kết quả học tập của học sinh đối với từng môn học, đề tài tiến hành tính điểm trung bình của mỗi môn dựa trên điểm số của toàn bộ học sinh.

Điểm trung bình môn học được tính theo công thức:

$$[X = \frac{\sum_{i=1}^n X_i}{n}]$$

Trong đó:

- X: Điểm trung bình của môn học.
- X_i : Điểm của học sinh thứ i.
- n: Tổng số học sinh có điểm ở môn học đó.

Sau khi tính điểm trung bình của tất cả các môn học, tiến hành so sánh kết quả để xác định những môn có điểm trung bình cao và thấp nhất.

Kết quả này giúp đánh giá mức độ tiếp thu kiến thức của học sinh đối với từng môn học, đồng thời phản ánh sự khác biệt về năng lực giữa các lĩnh vực kiến thức khác nhau.

4.3. Thống kê xếp loại học lực

Sau khi tính GPA của từng học sinh, đề tài tiến hành phân loại học lực theo các mức:

- Giỏi (GPA $\geq 8,0$)


- Khá ($6,5 \leq \text{GPA} < 8,0$)
- Trung bình ($\text{GPA} < 6,5$)

Kết quả thống kê cho thấy:

- Nhóm học sinh Khá chiếm tỷ lệ lớn nhất.
- Nhóm học sinh Giỏi chiếm tỷ lệ tương đối cao.
- Số lượng học sinh thuộc nhóm Trung bình chiếm tỷ lệ nhỏ hơn.

Qua kết quả trên có thể nhận thấy phần lớn học sinh có kết quả học tập ổn định và đạt mức từ Khá trở lên. Điều này phản ánh chất lượng học tập tương đối tốt của tập dữ liệu khảo sát.

Biểu đồ thống kê học lực giúp trực quan hóa số lượng học sinh trong từng nhóm, từ đó hỗ trợ việc đánh giá và so sánh kết quả học tập một cách dễ dàng hơn.




Hình 4.2: Biểu đồ thống kê xếp loại học lực học sinh

4.4. Học sinh có điểm trung bình cao nhất

Để xác định những học sinh có thành tích nổi bật nhất, đề tài tiến hành sắp xếp GPA của toàn bộ học sinh theo thứ tự giảm dần.

Kết quả cho thấy nhóm học sinh đứng đầu đều đạt mức GPA rất cao và có kết quả đồng đều ở hầu hết các môn học.

Biểu đồ Top 10 học sinh có GPA cao nhất giúp trực quan hóa sự chênh lệch giữa các học sinh xuất sắc và phần còn lại của lớp. Những học sinh này có thể được xem là nhóm tiêu biểu, phản ánh khả năng học tập tốt và có tiềm năng đạt kết quả cao trong kỳ thi đại học.



Hình 4.3: Biểu đồ Top học sinh có điểm trung bình cao nhất

4.5. Phân cụm học sinh bằng thuật toán K-Means

Đề tài sử dụng thuật toán K-Means để phân nhóm học sinh dựa trên ba đặc trưng:


- GPA.
- Số giờ học mỗi tuần.
- Số buổi nghỉ học.

Thuật toán K-Means chia dữ liệu thành ba cụm khác nhau, trong đó mỗi cụm đại diện cho một nhóm học sinh có đặc điểm học tập tương đồng.

Kết quả phân cụm giúp:

- Nhận biết nhóm học sinh có thành tích cao và chăm chỉ học tập.
- Xác định nhóm học sinh có nguy cơ đạt kết quả thấp.
- Hỗ trợ xây dựng các giải pháp học tập phù hợp đối với từng nhóm đối tượng.

Biểu đồ phân cụm K-Means cho thấy sự phân bố tương đối rõ ràng giữa các nhóm học sinh, chứng minh rằng dữ liệu có khả năng phân loại tốt.



Hình 4.4: Phân cụm học sinh bằng K-Means

4.6. Dự đoán khả năng đỗ đại học bằng Random Forest và Logistic Regression

Để dự đoán khả năng đỗ hoặc trượt đại học của học sinh, đề tài áp dụng hai mô hình học máy:

- Random Forest.
- Logistic Regression.

Các đặc trưng đầu vào của mô hình bao gồm:

- Điểm các môn học.
- Số giờ học mỗi tuần.
- Số buổi nghỉ học.

Sau khi chia dữ liệu thành tập huấn luyện và tập kiểm tra, hai mô hình được xây dựng và đánh giá độ chính xác.

Kết quả cho thấy mô hình Random Forest đạt độ chính xác cao và cho khả năng dự đoán tốt hơn so với Logistic Regression. Điều này cho thấy Random Forest phù hợp với bài toán dự đoán khả năng đỗ đại học trong bộ dữ liệu nghiên cứu.

Việc áp dụng các thuật toán học máy giúp tăng tính tự động trong quá trình đánh giá và hỗ trợ đưa ra các dự báo chính xác hơn.

Mô hình	Độ chính xác
Random Forest	0.79
Logistic Regression	0.83

Hình 4.5: Random Forest và Logistic Regression

4.7. Nhận xét chung

Thông qua quá trình phân tích dữ liệu điểm thi của học sinh, có thể rút ra một số nhận xét quan trọng như sau:

- Phần lớn học sinh có GPA ở mức Khá và Trung bình.
- Điểm số giữa các học sinh có sự phân hóa tương đối rõ ràng.
- Kết quả học tập chịu ảnh hưởng bởi số giờ học và số buổi nghỉ học.
- Thuật toán K-Means đã phân chia dữ liệu thành các nhóm học sinh có đặc điểm tương đồng.
- Mô hình Random Forest và Logistic Regression có khả năng dự đoán kết quả đỗ hoặc trượt đại học với độ chính xác cao.
- Việc kết hợp giữa phân tích dữ liệu và học máy giúp nâng cao khả năng đánh giá và dự báo kết quả tuyển sinh đại học.

Nhìn chung, kết quả nghiên cứu cho thấy việc ứng dụng Khoa học dữ liệu trong giáo dục có ý nghĩa thực tiễn cao, góp phần hỗ trợ học sinh và nhà trường trong việc đánh giá năng lực học tập cũng như đưa ra các định hướng học tập phù hợp.

CHƯƠNG 5. PHÂN CỤM VÀ DỰ ĐOÁN KHẢ NĂNG ĐỒ ĐẠI HỌC

5.1. Giới thiệu bài toán phân cụm và dự đoán

Trong lĩnh vực Khoa học dữ liệu, phân cụm dữ liệu (Clustering) và dự đoán (Prediction) là hai kỹ thuật quan trọng của học máy được ứng dụng rộng rãi trong nhiều lĩnh vực, đặc biệt là giáo dục.

Phân cụm dữ liệu là phương pháp học máy không giám sát (Unsupervised Learning), cho phép tự động chia tập dữ liệu thành các nhóm có đặc điểm tương đồng mà không cần dữ liệu có nhãn trước.

Trong khi đó, dự đoán là phương pháp học máy có giám sát (Supervised Learning), sử dụng dữ liệu đã có nhãn để xây dựng mô hình dự đoán kết quả của các đối tượng mới.

Trong lĩnh vực giáo dục, hai phương pháp này giúp:

- Nhận diện các nhóm học sinh có đặc điểm học tập tương đồng.
- Đánh giá mức độ phân hóa học lực giữa các học sinh.
- Dự đoán khả năng đỗ hoặc trượt đại học.
- Hỗ trợ giáo viên và học sinh đưa ra các phương pháp học tập phù hợp.

Trong đề tài này, thuật toán K-Means được sử dụng để phân cụm học sinh, đồng thời hai mô hình Random Forest và Logistic Regression được sử dụng để dự đoán khả năng đỗ đại học của học sinh.

5.2. Chuẩn bị dữ liệu

Trước khi thực hiện phân cụm và dự đoán, dữ liệu cần được xử lý và chuẩn hóa nhằm đảm bảo kết quả đạt độ chính xác cao.

Các thuộc tính được sử dụng trong đề tài gồm:

- Điểm Toán.
- Điểm Ngữ văn.
- Điểm Ngoại ngữ.
- Điểm Vật lý.
- Điểm Hóa học.
- Điểm Sinh học.
- Điểm Lịch sử.
- Điểm Địa lý.
- Số giờ học mỗi tuần.

- Số buổi nghỉ học.
- GPA của học sinh.

Quá trình chuẩn bị dữ liệu gồm:

Bước 1: Làm sạch dữ liệu

Các giá trị thiếu hoặc không hợp lệ được kiểm tra và xử lý nhằm tránh ảnh hưởng đến kết quả phân tích.

Bước 2: Chuẩn hóa dữ liệu

Dữ liệu được chuyển về cùng định dạng và kiểu dữ liệu số phù hợp với các thuật toán học máy.

Bước 3: Tạo tập dữ liệu đầu vào

Sau khi xử lý, dữ liệu được chuyển thành ma trận số để làm đầu vào cho các mô hình K-Means, Random Forest và Logistic Regression.

Việc chuẩn bị dữ liệu giúp nâng cao độ chính xác và độ tin cậy của mô hình.

5.3. Thực hiện phân cụm bằng thuật toán K-Means

Sau khi hoàn tất quá trình tiền xử lý dữ liệu, đề tài tiến hành áp dụng thuật toán K-Means để phân cụm học sinh.

Các thuộc tính được sử dụng để phân cụm gồm:

- Điểm trung bình GPA.
- Số giờ học mỗi tuần.
- Số buổi nghỉ học.

Trong đề tài, số cụm được lựa chọn là:

$$[K = 3]$$

Ba cụm tương ứng với ba nhóm học sinh có đặc điểm học tập khác nhau:

- Nhóm học sinh có kết quả học tập cao.
- Nhóm học sinh có kết quả học tập khá.
- Nhóm học sinh có kết quả học tập trung bình.

Quá trình thực hiện gồm các bước:

Bước 1: Khởi tạo ngẫu nhiên ba tâm cụm.

Bước 2: Tính khoảng cách từ từng học sinh đến các tâm cụm.

Bước 3: Gán học sinh vào cụm gần nhất.

Bước 4: Cập nhật lại vị trí tâm cụm.

Bước 5: Lặp lại quá trình cho đến khi các tâm cụm ổn định.

Kết thúc quá trình huấn luyện, mỗi học sinh sẽ được gán vào một cụm tương ứng dựa trên sự tương đồng về kết quả học tập.

5.4. Kết quả phân cụm

Kết quả phân cụm cho thấy dữ liệu học sinh được chia thành ba nhóm khác nhau:

- Cụm 1: Nhóm học sinh có GPA cao và số giờ học lớn.
- Cụm 2: Nhóm học sinh có kết quả học tập ở mức khá.
- Cụm 3: Nhóm học sinh có GPA thấp hoặc số buổi nghỉ học nhiều.

Biểu đồ phân cụm K-Means cho thấy các nhóm học sinh được hình thành tương đối rõ ràng và có sự khác biệt nhất định.


Thông qua kết quả phân cụm, có thể nhận diện được các nhóm học sinh có đặc điểm học tập tương đồng, từ đó hỗ trợ việc đánh giá và quản lý học tập hiệu quả hơn.

Kết quả phân tích cho thấy nhóm học sinh có kết quả học tập cao thường có các đặc điểm:

- Điểm GPA cao.
- Số giờ học mỗi tuần lớn.
- Số buổi nghỉ học thấp.
- Đạt điểm cao ở nhiều môn học quan trọng.

Ngược lại, nhóm học sinh có kết quả học tập thấp thường có số giờ học ít hơn và số buổi nghỉ học cao hơn.

Điều này cho thấy thời gian học tập và ý thức chuyên cần có ảnh hưởng đáng kể đến kết quả học tập của học sinh.



Hình 5.1: Biểu đồ kết quả phân cụm K-Means

5.5. Dự đoán khả năng đỗ đại học

Bên cạnh phân cụm dữ liệu, đề tài còn sử dụng hai mô hình học máy có giám sát gồm:

- Random Forest.
- Logistic Regression.

Mục tiêu của hai mô hình là dự đoán khả năng đỗ hoặc trượt đại học của học sinh dựa trên:

- Điểm các môn học.
- Số giờ học mỗi tuần.
- Số buổi nghỉ học.

Sau khi chia dữ liệu thành tập huấn luyện và tập kiểm tra, mô hình được huấn luyện và đánh giá thông qua chỉ số Accuracy.

Kết quả thực nghiệm cho thấy cả hai mô hình đều có khả năng dự đoán tương đối tốt. Trong đó, Random Forest thường cho độ chính xác cao hơn Logistic Regression nhờ khả năng xử lý dữ liệu phức tạp và giảm hiện tượng quá khớp.

	A	B	C	D	E
1	MaHS	KhoiXetTuyen	TruongDangKy	DiemXetTuyen	KetQua
2	HS001	A00	Dai hoc Bach Khoa Ha Noi	21.5	Truot
3	HS002	D01	Dai hoc Cong Nghiep Ha Noi	19.6	Truot
4	HS003	C00	Dai hoc Giao Thong Van Tai	22.3	Do
5	HS004	C00	Dai hoc Cong Nghiep Ha Noi	23.8	Do
6	HS005	A00	PTIT	28.9	Do
7	HS006	B00	Dai hoc Thuong Mai	14.2	Truot
8	HS007	C00	Dai hoc Giao Thong Van Tai	16.1	Truot
9	HS008	A01	Dai hoc Giao Thong Van Tai	20.2	Truot
10	HS009	A01	PTIT	22	Truot
11	HS010	C00	Dai hoc Bach Khoa Ha Noi	19.1	Truot
12	HS011	A01	Dai hoc Giao Thong Van Tai	17.3	Truot
13	HS012	D01	Dai hoc Cong Nghiep Ha Noi	24.2	Do
14	HS013	C00	Dai hoc Cong Nghiep Ha Noi	17.1	Truot
15	HS014	A00	Dai hoc Thuong Mai	12.8	Truot
16	HS015	B00	PTIT	16.3	Truot
17	HS016	A01	Dai hoc Thuong Mai	24.9	Do
18	HS017	C00	Dai hoc Thuong Mai	20.3	Truot
19	HS018	B00	Dai hoc Bach Khoa Ha Noi	14.1	Truot
20	HS019	B00	Dai hoc Bach Khoa Ha Noi	21.8	Truot
21	HS020	B00	Dai hoc Bach Khoa Ha Noi	17.7	Truot
22	HS021	A00	Dai hoc Thuong Mai	18.6	Truot
23	HS022	A01	Dai hoc Cong Nghiep Ha Noi	16.4	Truot
24	HS023	A00	Dai hoc Cong Nghiep Ha Noi	16.7	Truot
25	HS024	A00	Dai hoc Cong Nghiep Ha Noi	18.2	Truot
26	HS025	A01	Dai hoc Giao Thong Van Tai	19.4	Truot
27	HS026	C00	Dai hoc Thuong Mai	24.1	Do
28	HS027	C00	Dai hoc Giao Thong Van Tai	17.9	Truot
29	HS028	A01	Dai hoc Bach Khoa Ha Noi	13	Truot

Xep_hang_hoc_sinh Thông_ke Phan_cum_KMeans **Danh_sach_Do_Truot**

Hình 5.2: Danh sách dự đoán Đỗ Trượt

#	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S
1	MaHS	GioiTinh	Toan	NguVan	NgoaiNgu	VatLy	HoaHoc	SinhHoc	LichSu	DiaLy	SoGioHoc	SoBuoilNghihoc	KhoiXetTuyen	TruongDangKy	DiemXetTuyen	KetQua	GPA	Xep_loai	Danh_gia
2	HS001	Nu	3.1	8.4	3.7	9.6	8.8	7	6.6	5	25	19	A00	Dai hoc Bach Khoa Ha Noi	21.5	Truot	6.52	Khá	Học lực khá
3	HS002	Nam	7.5	3.1	9	9.9	6.4	5.1	6.4	8.8	16	13	D01	Dai hoc Cong Nghiep Ha Noi	19.6	Truot	7.02	Khá	Học lực khá
4	HS003	Nam	5.8	4.4	9.2	7.8	4.2	9.2	9	8.9	27	1	C00	Dai hoc Giao Thong Van Tai	22.3	Do	7.31	Khá	Học lực khá
5	HS004	Nu	5.2	6.5	3.6	6.6	8.6	3	8.3	9	29	3	C00	Dai hoc Cong Nghiep Ha Noi	23.8	Do	6.35	Trung bình	Cần cải thiện thể
6	HS005	Nu	9.6	7.7	7.2	9.6	9.7	9.5	4.7	3.7	35	2	A00	PTIT	28.9	Do	7.71	Khá	Học lực khá
7	HS006	Nam	6.3	7.6	8.6	8.9	3.1	4.8	9.5	9	34	11	B00	Dai hoc Thuong Mai	14.2	Truot	7.22	Khá	Học lực khá
8	HS007	Nu	8.5	7.3	3.4	6.9	9.4	6.4	4.3	4.5	20	4	C00	Dai hoc Giao Thong Van Tai	16.1	Truot	6.34	Trung bình	Cần cải thiện thể
9	HS008	Nu	7.2	8.4	3.5	9.5	8.4	6.4	6.5	6.5	15	16	A01	Dai hoc Giao Thong Van Tai	20.2	Truot	7.05	Khá	Học lực khá
10	HS009	Nam	5.4	6.3	7.7	8.9	8.7	9.3	7.9	9.6	15	12	A01	PTIT	22	Truot	7.98	Khá	Học lực khá
11	HS010	Nam	9.1	9.1	9.2	6.2	8.9	9.2	4.2	5.8	39	3	C00	Dai hoc Bach Khoa Ha Noi	19.1	Truot	7.71	Khá	Học lực khá
12	HS011	Nam	4.1	7.8	6.5	6.7	8.4	7.6	4	3.1	14	6	A01	Dai hoc Giao Thong Van Tai	17.3	Truot	6.02	Trung bình	Cần cải thiện thể
13	HS012	Nam	8.1	6.3	9.8	6.7	9.1	7.7	8.6	6.6	12	10	D01	Dai hoc Cong Nghiep Ha Noi	24.2	Do	7.86	Khá	Học lực khá
14	HS013	Nam	5.3	7.1	3.1	5.2	3.4	7.4	5.4	4.6	11	14	C00	Dai hoc Cong Nghiep Ha Noi	17.1	Truot	5.19	Trung bình	Cần cải thiện thể
15	HS014	Nam	3.3	5	6.3	6.2	3.3	4.3	3.1	3.5	28	15	A00	Dai hoc Thuong Mai	12.8	Truot	4.38	Trung bình	Cần cải thiện thể
16	HS015	Nu	8.5	5.8	5.8	7.4	4.1	3.7	5.1	8.3	33	18	B00	PTIT	16.3	Truot	6.09	Trung bình	Cần cải thiện thể
17	HS016	Nam	6.7	7.9	8.5	9.7	7.9	3.1	9.1	7	29	11	A01	Dai hoc Thuong Mai	24.9	Do	7.49	Khá	Học lực khá
18	HS017	Nu	5.8	6.1	9	4.9	6.4	3.8	10	4.2	33	12	C00	Dai hoc Thuong Mai	20.3	Truot	6.28	Trung bình	Cần cải thiện thể
19	HS018	Nam	5.9	8.4	8.2	7.1	4.1	4.1	8.2	3.6	32	15	B00	Dai hoc Bach Khoa Ha Noi	14.1	Truot	6.2	Trung bình	Cần cải thiện thể
20	HS019	Nam	6.9	3.8	4.1	7	5.4	9.5	4.5	5.3	37	15	B00	Dai hoc Bach Khoa Ha Noi	21.8	Truot	5.81	Trung bình	Cần cải thiện thể
21	HS020	Nam	8.4	9.3	6.5	7.7	3.4	5.9	3.3	7.4	25	19	B00	Dai hoc Bach Khoa Ha Noi	17.7	Truot	6.49	Trung bình	Cần cải thiện thể
22	HS021	Nu	5.6	8.9	7.6	4.7	8.3	3.3	5.3	4.4	29	16	A00	Dai hoc Thuong Mai	18.6	Truot	6.01	Trung bình	Cần cải thiện thể
23	HS022	Nam	5.9	6.5	3.5	7	9.9	8.8	9.8	7.5	19	17	A01	Dai hoc Cong Nghiep Ha Noi	16.4	Truot	7.36	Khá	Học lực khá
24	HS023	Nu	6.8	8.2	3.1	3.2	6.7	3.5	6.5	5.8	14	15	A00	Dai hoc Cong Nghiep Ha Noi	16.7	Truot	5.48	Trung bình	Cần cải thiện thể
25	HS024	Nu	6.1	3.9	4.7	4	8.1	7.5	6.9	6.7	30	11	A00	Dai hoc Cong Nghiep Ha Noi	18.2	Truot	5.99	Trung bình	Cần cải thiện thể
26	HS025	Nu	8.5	5.6	3.5	7.4	8.5	8.9	3	6.8	20	12	A01	Dai hoc Giao Thong Van Tai	19.4	Truot	6.52	Khá	Học lực khá
27	HS026	Nam	9.5	6.2	7.6	6.2	7.2	7.3	9.7	8.2	38	20	C00	Dai hoc Thuong Mai	24.1	Do	7.74	Khá	Học lực khá
28	HS027	Nam	6.5	8.9	7.4	9	6.4	3.5	3.3	5.7	35	16	C00	Dai hoc Giao Thong Van Tai	17.9	Truot	6.34	Trung bình	Cần cải thiện thể
29	HS028	Nu	3.6	7.5	4.2	5.2	8.3	9.1	9.7	9.1	21	10	A01	Dai hoc Bach Khoa Ha Noi	13	Truot	7.09	Khá	Học lực khá

Xep_hang_hoc_sinh Thông_ke Phan_cum_KMeans **Danh_sach_Do_Truot** Random_Forest **Bang_du_lieu**

Hình 5.3: Thống kê chi tiết và đánh giá có thể cải thiện để Đỗ

5.6. Đánh giá kết quả

Kết quả thực nghiệm cho thấy:

- Thuật toán K-Means có khả năng phân chia học sinh thành các nhóm có đặc điểm học tập tương đồng.
- Random Forest và Logistic Regression có khả năng dự đoán kết quả đỗ hoặc trượt đại học với độ chính xác cao.
- GPA, số giờ học và số buổi nghỉ học là những yếu tố có ảnh hưởng lớn đến kết quả học tập.

Việc áp dụng các thuật toán học máy giúp:

- Hỗ trợ đánh giá năng lực học tập của học sinh.
- Dự đoán khả năng trúng tuyển đại học.
- Phát hiện các nhóm học sinh cần được hỗ trợ học tập.
- Cung cấp cơ sở dữ liệu cho các nghiên cứu giáo dục trong tương lai.

Mặc dù kết quả đạt được tương đối khả quan, mô hình vẫn phụ thuộc vào chất lượng dữ liệu đầu vào. Trong tương lai có thể mở rộng nghiên cứu bằng cách bổ sung thêm nhiều thuộc tính khác hoặc áp dụng các thuật toán học máy nâng cao để cải thiện độ chính xác của mô hình.

TÀI LIỆU THAM KHẢO

Tài liệu tiếng Việt

- [1] Nguyễn Văn Tuấn, Phân tích dữ liệu với Python, Nhà xuất bản Khoa học và Kỹ thuật, Hà Nội, 2021.
- [2] Trần Minh Quang, Nhập môn Khoa học dữ liệu, Nhà xuất bản Đại học Quốc gia TP. Hồ Chí Minh, 2020.
- [3] Nguyễn Đình Thọ, Phương pháp nghiên cứu khoa học trong kinh doanh, Nhà xuất bản Lao động – Xã hội, 2019.

Tài liệu tiếng Anh

- [4] Wes McKinney, Python for Data Analysis: Data Wrangling with Pandas, NumPy, and Jupyter, 3rd Edition, O'Reilly Media, 2022.
- [5] Aurélien Géron, Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow, 3rd Edition, O'Reilly Media, 2022.
- [6] Jake VanderPlas, Python Data Science Handbook, O'Reilly Media, 2016.
- [7] Christopher M. Bishop, Pattern Recognition and Machine Learning, Springer, 2006.
- [8] Trevor Hastie, Robert Tibshirani, Jerome Friedman, The Elements of Statistical Learning, Springer, 2009.

Tài liệu về Machine Learning và K-Means

- [9] Stuart Russell, Peter Norvig, Artificial Intelligence: A Modern Approach, 4th Edition, Pearson, 2020.
- [10] J. MacQueen, “Some Methods for Classification and Analysis of

Multivariate Observations”, Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability, 1967.

[11] Leo Breiman, “Random Forests”, Machine Learning Journal, Vol. 45, No. 1, pp. 5–32, 2001.

[12] David W. Hosmer, Stanley Lemeshow, Rodney X. Sturdivant, Applied Logistic Regression, 3rd Edition, Wiley, 2013.

Tài liệu về Python và thư viện sử dụng

[13] Pandas Documentation. Available: <https://pandas.pydata.org/>

[14] NumPy Documentation. Available: <https://numpy.org/>

[15] Matplotlib Documentation. Available: <https://matplotlib.org/>

[16] Scikit-learn Documentation. Available: <https://scikit-learn.org/>

[17] OpenPyXL Documentation. Available:
<https://openpyxl.readthedocs.io/>